

Домашнее задание 2. Морфоразбор, WSD

Автор: Коновалов Валентин Русланович

Репозиторий: https://github.com/valkon29/lingvo_dataset_vk

1. Сбор данных

Осуществлѐн в ноутбуке `collect_data.ipynb` Датасет сохранѐн в файл `vk_dataset.csv`

Источник данных

Платформа: ВКонтакте (через API)

Тип контента: Посты и комментарии к ним из сообществ

Я выбрал несколько сообществ с тематикой наука или образование. Полный список:

- <https://vk.com/arzamas.academy> (гуманитарные науки)
- https://vk.com/art_and_stories (искусство)
- https://vk.com/hotel_historian (история)
- <https://vk.com/mathhedgehog> (математика)
- <https://vk.com/rgoclub> (география)

Критерии отбора

- Период: брались последние посты (без ограничений по времени)
- Объѐм: примерно по 100 постов на сообщество и все комментарии к ним

Объѐм датасета

- Итого записей: 5 743
 - Постов: 484
 - Комментариев: 5 259
- Средний объѐм текста: ~27 токенов на запись

Прочие замечания

Стоит отметить, что комментарии, по понятным причинам, в среднем отличаются от постов более неформальным стилем

2. Предобработка и разметка

Код для этого и последующих пунктов доступен в ноутбуке `analysis.ipynb`

Пайплайн предобработки

1. Очистка текста:

- Удаление лишних пробелов
- Удаление эмодзи
- Замена ссылок на "URL"
- Замена упоминаний пользователей на "USER"

2. Токенизация:

- Инструмент: NLTK `word_tokenize()`
- Фильтрация: только слова с кириллицей или латиницей
- Приведение к нижнему регистру

3. Морфологический разбор:

- Инструмент: `pymorphy3.MorphAnalyzer()`
- Версия: `pymorphy3 2.0.6`
- Выбор варианта, которому модель присвоила наибольшую вероятность

Особенности `pymorphy3`

Достоинства:

- Современный морфологический анализатор
- Хорошая поддержка русского языка
- Хорошая устойчивость к неологизмам и редким словам
- Высокая скорость обработки

Ограничения/недостатки:

- Является контекстно-независимым, поэтому не способен хорошо различать омонимы и прочие неоднозначности. Он использует предобученные вероятности для выбора наиболее вероятного разбора
- Не распознаёт опечатки и грамматические ошибки

Обоснование выбора пайплайна

Мне кажется, что для учебной задачи эта библиотека подходит очень хорошо, так как она довольно современная, но в то же время не такая мощная, как некоторые другие обучаемые модели, поэтому на её примере можно наблюдать различные ошибки в разборе

3. Анализ морфоразбора на сложных примерах

Искусственные примеры

Здесь приведён анализ разбора специально подобранных «сложных» примеров.

Омонимия сущ./глагол:

1. "печь"

- Контекст: "Пироги печь — это искусство"
- Выход `pymorphy3`:

```

пироги -> пирог (NOUN) [NOUN, inan, masc plur, accs]
печь -> печь (NOUN) [NOUN, inan, femn sing, nomn]
это -> это (PRCL) [PRCL]
искусство -> искусство (NOUN) [NOUN, inan, neut sing, nomn]

```

- Проблема: омонимия между существительным и глаголом (печь = существительное/глагол). Модель выбирает вариант с глаголом как более вероятный без учёта контекста
- Возможное решение: учитывать контекст

2. "пила"

- Контекст: "Она пила кофе"
- Выход рутморphy3:

```

она -> она (NPRO) [NPRO, femn, 3per, Anph sing, nomn]
пила -> пила (NOUN) [NOUN, inan, femn sing, nomn]
кофе -> кофе (NOUN) [NOUN, inan, masc, Fixd, Ms-f sing, gent]

```

- Проблема: Омонимия между существительным и глаголом (пила = существительное/прошедшее время глагола). Модель выбирает вариант с глаголом как более вероятный без учёта контекста
- Возможное решение: учитывать контекст

Неправильный выбор ГЗ:

1. "стены"

- Контекст: "В комнате не было стены"
- Выход рутморphy3:

```

в -> в (PREP) [PREP]
комнате -> комната (NOUN) [NOUN, inan, femn sing, loc]
не -> не (PRCL) [PRCL]
было -> быть (VERB) [VERB, impf, intr neut, sing, past, indc]
стены -> стена (NOUN) [NOUN, inan, femn sing, gent]

```

- Проблема: Многозначность падежной формы стены (родительный или именительный падеж). В итоге модель выбирает неправильное грамматическое значение
- Возможное решение: учитывать контекст

Неологизмы:

1. "Превед"

- Контекст: "Превед, медведь"
- Выход рутморphy3:

```

превед -> преведа (NOUN) [NOUN, inan, femn plur, gent]
медведь -> медведь (NOUN) [NOUN, anim, masc sing, nomn]

```

- Проблема: Неологизм из интернет-мемов. Модель его не знает и выдаёт явно не ту лемму
- Возможное решение: Пополнить словарь неологизмами из интернет-мемов

4. Анализ морфоразбора собранного датасета

Для этого пункта я взял выборку из 50 записей (включают в себя посты и комментарии). Примеры ошибок в их разборе приведены ниже.

Опечатки в тексте

1. "снимокПрекрасная"

- Контекст: "Великолепный снимокПрекрасная наша страна"
- Выход рутморphy3:

```

великолепный -> великолепный (ADJF) [ADJF, Qual masc, sing, nomn]
снимокпрекрасная -> снимокпрекрасный (ADJF) [ADJF femn, sing, nomn]
наша -> наш (ADJF) [ADJF, Apro femn, sing, nomn]
страна -> страна (NOUN) [NOUN, inan, femn sing, nomn]

```

- Проблема: Анализатор не распознаёт отсутствие пробела, считает два слова за одно. Хотя, строго говоря, это не проблема, а скорее особенность анализатора
- Возможное решение: Использовать более умную модель

2. "самоелы", "надствройку"

- Контекст: "Это же неудобно садиться, и так самоелы влетали в надствройку"
- Выход рутморphy3:

```

это -> это (PRCL) [PRCL]
же -> же (PRCL) [PRCL]
неудобно -> неудобно (ADVB) [ADVB, Prdx]
садиться -> садиться (INFN) [INFN, impf, intr]
и -> и (CONJ) [CONJ]
так -> так (CONJ) [CONJ]
самоелы -> самоелы (None) [UNKN]
влетали -> влетать (VERB) [VERB, impf, intr plur, past, indc]
в -> в (PREP) [PREP]
надствройку -> надствройка (NOUN) [NOUN, inan, femn sing, accs]

```

- Проблема: Анализатор не распознаёт опечатки, выдаёт в качестве лемм несуществующие слова. Хотя, строго говоря, это не проблема, а скорее особенность анализатора
- Возможное решение: Использовать более умную модель

Неологизмы

1. "нейро"

- Контекст: "в его альбоме(более 10 к фото) нет такого нейро!"
- Выход руморphy3:

```
его -> он (NPRO) [NPRO,masc,3per,Anph sing,accs]
альбоме -> альбом (NOUN) [NOUN,inan,masc sing,loct]
более -> более (ADVB) [ADVB]
к -> к (PREP) [PREP]
фото -> фото (NOUN) [NOUN,inan,neut,Fixd sing,loct]
нет -> нет (PRED) [PRED,pres]
такого -> такой (ADJF) [ADJF,Apro neut,sing,gent]
нейро -> нейро (None) [UNKN]
```

- Проблема: Современный технический неологизм, не опознан анализатором
- Возможное решение: Пополнить словарь техническими неологизмами

2. "мемным"

- Контекст: "Впрочем, «Кот Фриц» всё же считается прям самым мемным."
- Выход руморphy3:

```
впрочем -> впрочем (CONJ) [CONJ,Prnt]
кот -> кот (NOUN) [NOUN,anim,masc sing,nomn]
фриц -> фриц (NOUN) [NOUN,anim,masc sing,nomn]
всё -> всё (PRCL) [PRCL]
же -> же (PRCL) [PRCL]
считается -> считаться (VERB) [VERB,impf,intr sing,3per,pres,indc]
прям -> прям (PRCL) [PRCL]
самым -> самый (ADJF) [ADJF,Apro neut,sing,ablt]
мемным -> мёмный (ADJF) [ADJF masc,sing,ablt]
```

- Проблема: Неологизм из интернет-сленга. Модель его не знает и выдаёт не ту лемму, правильный вариант - "мемный"
- Возможное решение: Расширение словаря интернет-сленга

Лексическая омонимия

1. "брак":

- Контекст: "Сиречь брак выявится в процессе эксплуатации"

- Выход рутормфу3:

```
сиречь -> сиречь (CONJ) [CONJ]
брак -> брак (NOUN) [NOUN, inan, masc sing, accs]
выявится -> выявиться (VERB) [VERB, perf, intr sing, 3per, futr, indc]
в -> в (PREP) [PREP]
процессе -> процесс (NOUN) [NOUN, inan, masc sing, loc]
эксплуатации -> эксплуатация (NOUN) [NOUN, inan, femn sing, gent]
```

- Проблема: Лексическая омонимия слова брак (дефект vs супружество)
- Анализ разбора: Оба слова "брак" (дефект) и "брак" (супружество) будут иметь абсолютно одинаковый результат разбора. То есть здесь вовсе нет попытки распознать лексическую омонимию
- Возможное решение: учитывать контекст

Грамматическая омонимия

1. "производная"

- Контекст: "Символ слева корректнее называть «производная», а не «дифференциал»"
- Выход рутормфу3:

```
символ -> символ (NOUN) [NOUN, inan, masc sing, nomn]
слева -> слева (ADVB) [ADVB]
корректнее -> корректный (COMP) [COMP, Qual]
называть -> называть (INFN) [INFN, impf, tran]
производная -> производный (ADJF) [ADJF femn, sing, nomn]
а -> а (CONJ) [CONJ]
не -> не (PRCL) [PRCL]
дифференциал -> дифференциал (NOUN) [NOUN, inan, masc sing, nomn]
```

- Проблема: "производная" в данном случае это математический термин
- Возможное решение: учитывать контекст, пополнить словарь математическими терминами

2. "математика"

- Контекст: "Математика абстрактна, она вне реальности"
- Выход рутормфу3:

```
математика -> математик (NOUN) [NOUN, anim, masc sing, gent]
абстрактна -> абстрактный (ADJS) [ADJS, Qual femn, sing]
она -> она (NPRO) [NPRO, femn, 3per, Anph sing, nomn]
вне -> вне (PREP) [PREP]
реальности -> реальность (NOUN) [NOUN, inan, femn sing, gent]
```

- Проблема: "математика" в данном случае это название научной области, а не профессии
- Возможное решение: учитывать контекст, использовать более умную модель

5. Поиск дискурсивных/недревесных явлений

Эллипсис

Пример 1

Текст:

Сначала ученик боится цифр, потом дробей, потом математика начинает говорить буквами, затем - по-гречески и освоившему всё это ученику кажется, будто больше математике нечем его удивить. Как бы не так! Есть чем, и очень даже.

Разбор:

- «Есть чем, и очень даже» — эллипсис целой предикативной группы: «Есть чем [его удивить], и очень даже [чем его удивить]».

Недревесность: вершины отсутствуют — зависимые слова остаются без родителя. Дерево содержит «дыры», которые можно восстановить только из контекста.

Пример 2 Текст:

Может кто вспомнит, как назывались эти растишки? Росли на лугах, в предгорьях.

Разбор:

- «Росли на лугах» — эллипсис подлежащего: полная форма «[Они] росли на лугах».

Недревесность: нулевое подлежащее нарушает целостность дерева, восстановление требует выхода за границы предложения.

Парцелляция

Пример 1

Текст:

Не переживайте, Алексей! В свое время пришлось заморозить пару каналов на YouTube и Instagram. Трастовых и монетизированных.

Разбор:

- «Трастовых и монетизированных» — парцелированное определение к «каналов».
- В полной форме: «... заморозить пару трастовых и монетизированных каналов... »

Недревесность: при анализе по отдельным предложениям парсер не свяжет прилагательные из второго предложения с «каналов» из первого.

Референциальные цепочки

Недревесность: референциальные цепочки требуют перекрестных ссылок и общей идентичности между элементами, а дерево зависимостей допускает только строго иерархические связи

Пример 1

Цепочка пост+комментарии:

№	Текст
пост	 Женщина тундры впервые держит в руках зонт. Нюдяне — мать пятерых дочерей: Марии, Карины, Вероники, Майи и Виталины. Все вместе они живут в тундре на Ямале и ведут кочевой образ жизни.  Автор фото: Лейка Юрий, участник фотоконкурса «Самая красивая страна».
1	Зачем
2	В наше время у жителей тундры, особенно у кого есть родовые земли, которых арендуют Газпром, есть всё и даже больше!
3	Зонт в тундре нужен как в бане лыжи. Не надо записывать женщину в "отсталые". Здесь трагедия её народа: посмотрите на имена детей. Шла программа по русификации малых народов. Забирали в интернаты, отучали от языка, не регистрировали национальные имена.
4	URL
5	Борщом их в интернате кормят, а потом они не могут свою любимую каныгу кушать, не говоря про копальхен.
6	А он ей нужен?

Разбор:

Коммент	Местоимения	Референт
2	кого	жители тундры (с родовыми землями)
5	их, они	дети коренных народов (не названы явно)
6	он, ей	неясны

Пример 2

Цепочка пост+комментарии:

	Текст
пост	 Сколько манулов в России и можно ли их приручить? Вместе с нашими друзьями-экспертами из Сайлюгемского национального парка собрали интересные факты про одну из самых скрытных и редких диких кошек России. Напишите в комментариях, какой факт вас больше всего удивил 

Текст	
1	Никакой факт уже не удивляет))
2	Дикарей не приручить
3	Как же они выжили со слабым иммунитетом к инфекциям?
4	А что насчёт общения манулов между собой? Как дружат и множатся?
5	Видимо, в их краях таких инфекций нет ((
6	А зачем их приручать?
7	Удивил особый рацион

Разбор:

Коммент	Местоимения	Референт
3	они	дикари
4	собой	манулы
5	их	манулы
6	их	манулы